实验报告：从零开始构建 Fashion-MNIST 神经网络分类器

姓名：李茗瑄
学号：24300980036
资源链接：
(1)GitHub Repo 链接：https://github.com/trapidation/Fashion-MNIST-MLP-From-Scratch
(2)最优模型权重链接：
https://drive.google.com/file/d/1Cn9hmWsxaLSo19jLvusZAPAKQPsi5dBq/view?usp=drive_link

一.实验目的：

本实验旨在放弃现有的深度学习自动微分框架（如 PyTorch、TensorFlow 等），完全基于底层矩阵运算库（NumPy）通过从零手工构建并训练一个三层神经网络（MLP）分类器，以 Fashion-MNIST 数据集为实验目标，深入理解深度学习模型的核心机制及其在图像分类任务中的具体应用。

二.模型结构：

2.1 数据预处理

2.1.1 预处理操作

在开始部分先通过 offset=16（图片）或 offset=8（标签）剥离 IDX 文件的二进制头部元数据（如 Magic Number、维度信息等），直接获取有效像素与标签的字节流。之后使用 reshape(-1, 28 * 28)对空间特征进行展平，将原始 28x28 的二维图像空间重构为 784 维的一维特征向量，满足 MLP 全连接层对一维输入向量的硬性要求。接下来通过 astype(np.float32/int64)对数据进行精度转换，将图像转为 32 位浮点型以支撑反向传播中的高精度连续梯度计算；标签转为整型以精确对应交叉熵损失的类别索引。

2.1.2 数据集划分(data_loader.py)

官方原始数据集仅提供 60,000 张训练图与 10,000 张测试图。为满足实验要求中“根据验证集自动保存最优模型权重”及“超参数查找”的需求，代码通过 split_index = 50000 进行了 Hold-out 验证集切分：

（1）训练集：截取前 50,000 个样本，作为训练数据喂入网络，专用于反向传播计算梯度并更新权重参数。

（2）验证集：截取后 10,000 个样本。该部分不参与梯度更新，用于在每个 Epoch 结束时评估模型表现，辅助执行学习率衰减或早停机制

（3）测试集：保持独立的 10,000 个样本，作为纯净的无偏估计器，仅在训练彻底结束后运行一次，用于生成混淆矩阵并输出最终分类准确率。

2.2 模型定义(model.py)

2.2.1 参数初始化

采用极小随机正态分布（0.01*N(0,1)）初始化权重矩阵参数，避免梯度消失/爆炸；定义隐藏层维度与 L2 正则化系数。同时实现{RELU,Sigmoid,Leaky_RELU,GELU}四种激活函数及其导数。

2.2.2 前向传播

依次执行$\mathbf{Z}_1 = \mathbf{X}\mathbf{W}_1 + \mathbf{b}_1, \mathbf{A}_1 = \sigma(\mathbf{Z}_1), \mathbf{Z}_2 = \mathbf{A}_1\mathbf{W}_2 + \mathbf{b}_2$。利用 cache 字典记录前向传播的中间张量，避免反向传播时重复计算。

2.2.3 反向传播

结合 cache 缓存，利用链式法则计算损失函数对各层权重（$\mathbf{W}_1, \mathbf{W}_2$）和偏置（$\mathbf{b}_1, \mathbf{b}_2$）的偏导数，并叠加 L2 正则化的梯度偏置。

2.2.4 损失计算

结合 Softmax 分布，计算交叉熵损失（引入 10^{-8}防止 Log(0) 溢出），并附加基于权重平方和的 L2 正则化惩罚项（$\frac{\lambda}{2}\sum \mathbf{W}^2$）。

2.3 训练循环(train.py)

2.3.1 优化算法

采用小批次随机梯度下降法在每个 Epoch 开始前对训练集执行 np.random.permutation 乱序，按设定好的 batch_size 切分批次送入网络计算梯度并更新参数。采用乘法衰减策略（learning_rate * lr_decay），使得学习率随着 Epoch 的增加动态退火，帮助模型在训练后期跨越震荡，平稳收敛于极小值点。

2.3.2 状态评估

每个 Epoch 结束后，分别在训练集（截取前 5000 样本加速计算）和完整验证集上执行前向传播，计算并记录当前轮次的交叉熵 Loss 与分类准确率（Accuracy）。同时代码动态追踪 best_val_acc，一旦当前 Epoch 的验证集准确率超越历史最高值，立即拷贝当前网络的权重（$\mathbf{W}_1, \mathbf{b}_1, \mathbf{W}_2, \mathbf{b}_2$），并在训练结束后固化保存至 best_model.npz。

2.3.3 激活函数测评与可视化

遍历 RELU,Sigmoid,Leaky_RELU,GELU 四种激活函数，在统一的控制变量（隐藏层 128 维，学习率 0.1 等）下分别进行完整训练，横向对比其收敛上限。利用 Matplotlib 绘制双图：（1）单个模型训练/验证集的 Loss 与 Accuracy 趋势图；（2）四种不同激活函数在验证集上的准确率横向比对折线图。

2.4 测试分析(evaluate.py)

2.4.1 最优权重注入

读取保存的 best_model.npz 文件，初始化网络将训练态的参数矩阵无缝切换至推理态。

2.4.2 混淆矩阵绘制

利用 sklearn 统计网络预测类别与真实标签的联合分布，并以蓝阶热力图形式展现。

2.4.3 隐藏层可视化

实验提取隐藏层维度，固定种子的情况下随机选取 16 张进行隐藏神经元绘制权重热力图得出神经元喜好。

2.4.4 错例分析

选取所有预测标签 (y_pred) 与真实标签 (y_true) 不相等的样本索引数组。从中无放回地随机抽取 6 个样本，并将其从一维数组还原成 28x28 像素的二维图像矩阵，同时映射标签文本通过 CLASS_NAMES 列表，将数字格式的类别标签转换成字符串。

三.训练结果

3.1 最优训练过程

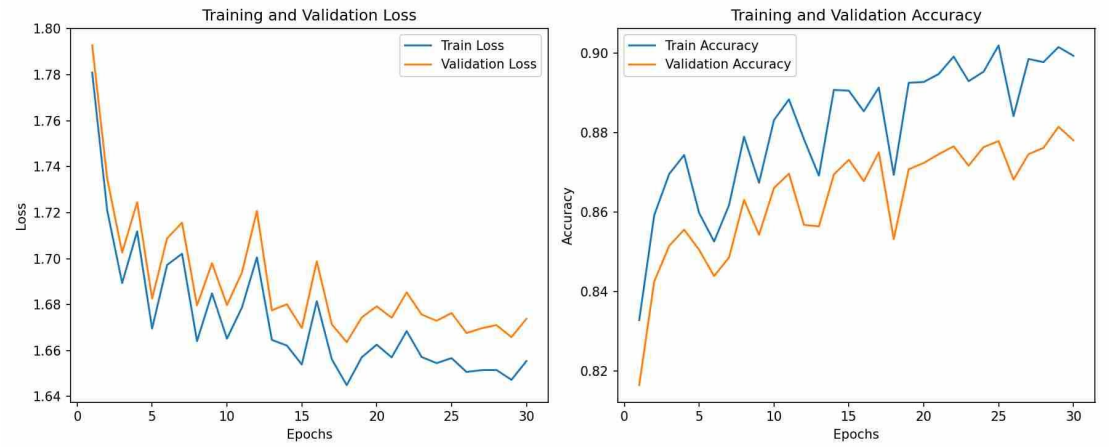

实验结果图片表明，模型处于稳定的学习过程，验证集准确率最终达到 87.8%，且并未出现梯度消失或梯度爆炸的情况。同时模型具有较为良好的泛化能力，仅存在轻微过拟合。然而在 Epochs10~15 之间存在较大震荡，可能是由于 Batch 大小或者数据偏差等超参数原因。

3.2 超参数对比

3.2.1 激活函数对比

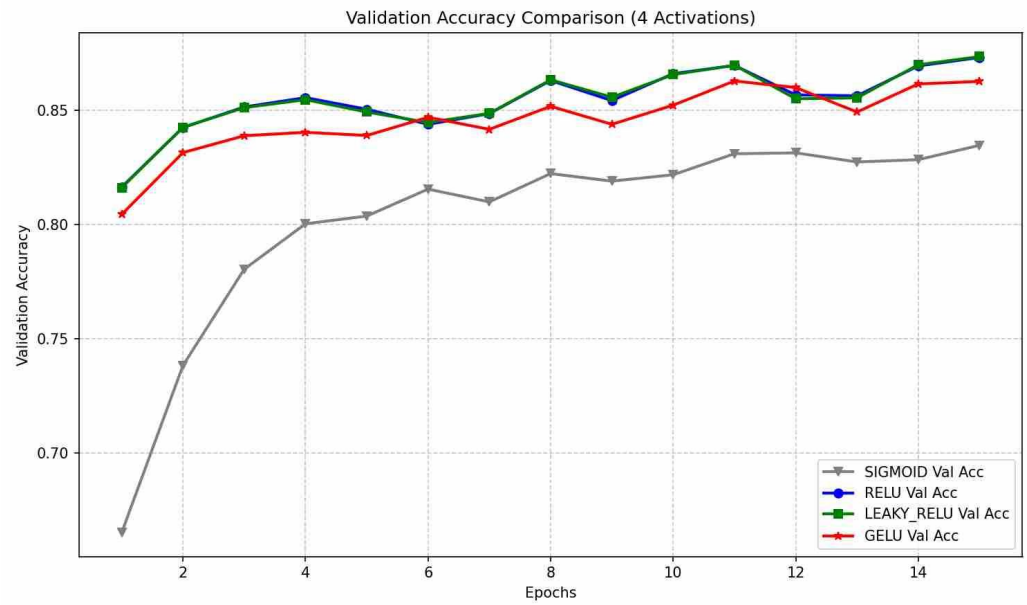

实验结果表明，对于图中四种超参数，RELU 与 Leaky_RELU 几乎没有差距，在四种激活函数之中表现最佳最终达到约 87.5%的收敛率，且在训练初期便表现了极强的特征捕捉能力。GELU 除去个别 Epochs 以外基本比前两种低 1~2 百分点。Sigmoid 收敛速度最慢，且初期准确度远远低于前面三种，这可能是由于 Sigmoid 在输入初期梯度接近于 0，导致训练缓慢。因此建议在类似的神经网络中优先采用 RELU 或 Leaky_RELU 的非线性激活函数。

3.2.2 隐藏层对比

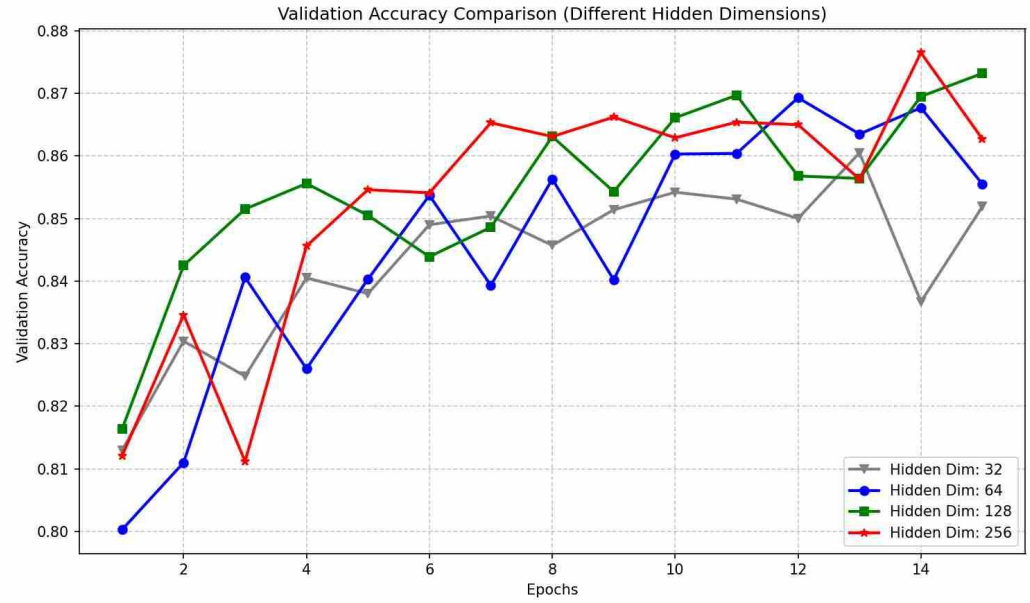

实验结果表明，隐藏层维度为 32 时表现最为稳定然而上限较低，最高约达到 86%的准确度，隐藏层维度为 64 时处于中间过度维度，震荡适中且后期具备一定上限。隐藏层维度为 128 时，模型在收敛速度、最终准确率及训练稳定性三者间表现最为平衡。隐藏层维度为

256 时虽然提升了模型上限，然而也带来了更高的不稳定性和训练难度。综上所述，维度为 128 时在性能和计算开销之间达到了最佳平衡，最适用于本次实验。

3.2.3 正则化参数对比

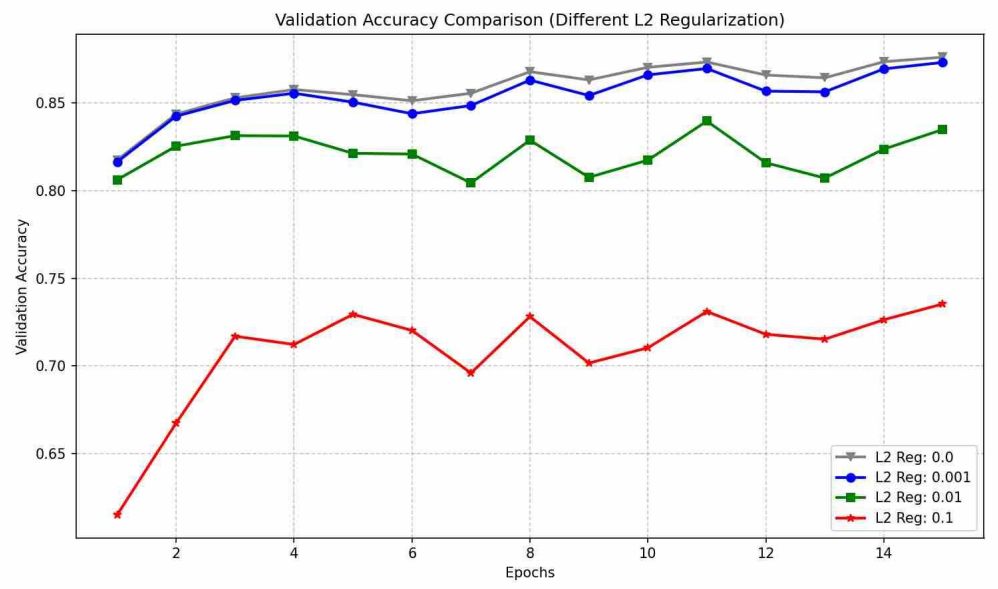

实验结果表明本实验对正则化敏感度较高，在无正则化或轻微正则化时准确度最高。随着正则化的增加，模型在优化过程中不断在“减小损失”和“压缩权重”之间剧烈拉锯，导致收敛过程极不稳定。为此，对于该实验而言，无需利用高正则化来抑制过拟合。

3.2.4 学习率对比

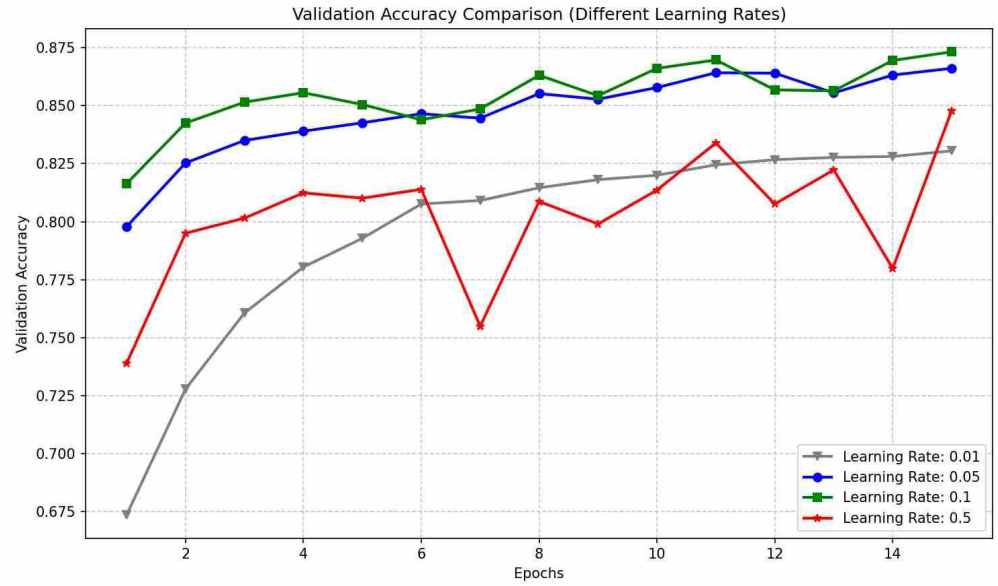

实验结果表明，学习率 0.01 时虽然持续上升，但由于步伐过小导致准确率提升缓慢，在 15 次 Epochs 之后准确度仅达到 83%左右。同时，学习率 0.5 时由于步伐过大，导致准确率震荡严重，且总体准确率低于剩下两种。学习率为 0.1 和 0.05 的时候准确率都处于一个逐步上升的类型，其中学习率为 0.1 时效果最好，达到了性能和稳定性的最佳平衡，最终达到了 87.5%的准确性。

四.测试评估

4.1 最优权重与混淆矩阵

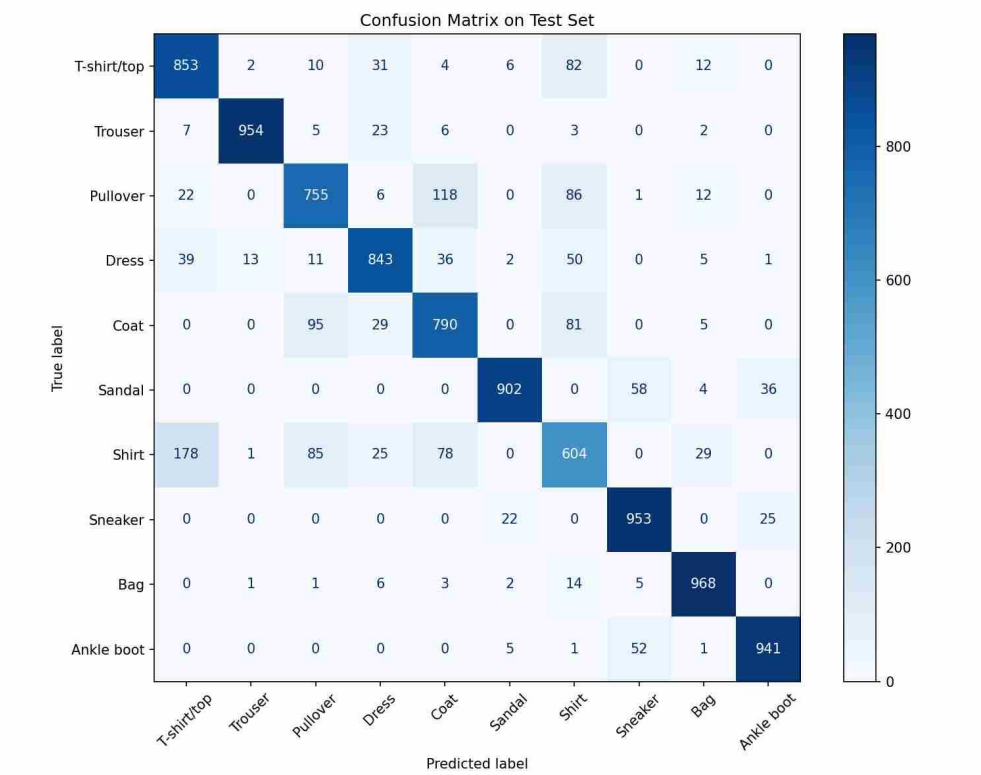

混淆矩阵结果显示，模型在 Trouser 和 Bag 等特征鲜明的类别上准确率极高（>95%）。主要的性能瓶颈在于上衣类（Shirt, Pullover, Coat）之间的相互误判。这表明模型在提取高度相似轮廓下的微观纹理特征方面仍有提升空间。为此，我们可以引入注意力机制关注局部特征如纽扣，领带来对 shirt 和 T-shirt 进行进一步区分。

4.2 权重可视化

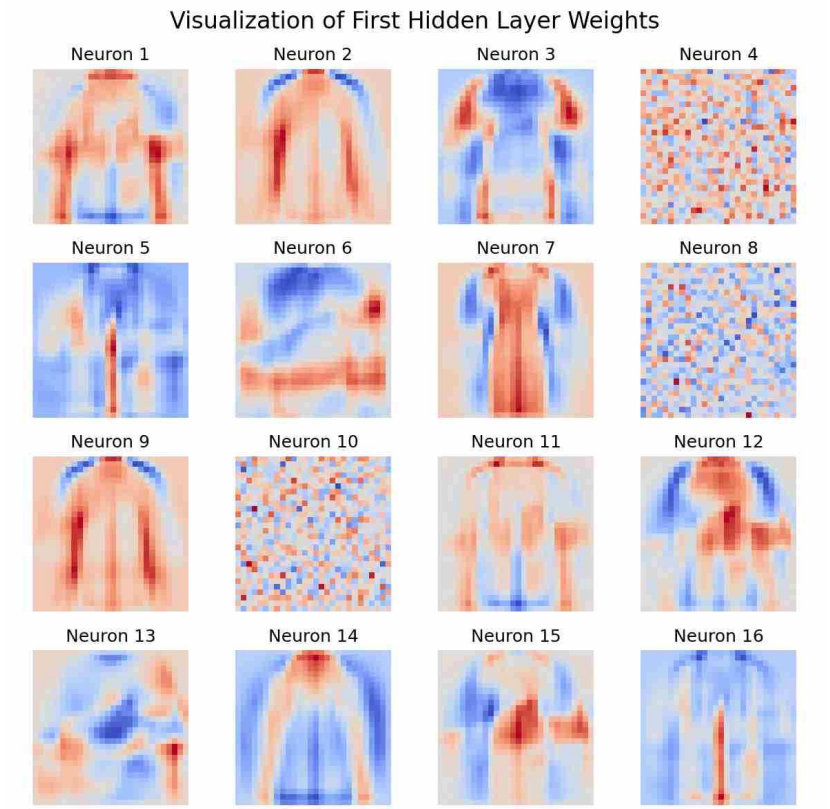

由实验结果图像可知，Neuron 1, 2, 7, 14 学习到了衣服、裙子的整体轮廓和边界。Neuron 5, 15 专注于领口、袖口或中心拉链/纽扣区域，这证明了网络具备良好的特征提取能力，能够将原始像素转化为具有语义特征的内部表示。而 Neuron 4, 8, 10 呈现随机噪声状，未学习到明显的几何特征，提示可能模型具有冗余或者训练程度不足。

4.3 错例分析

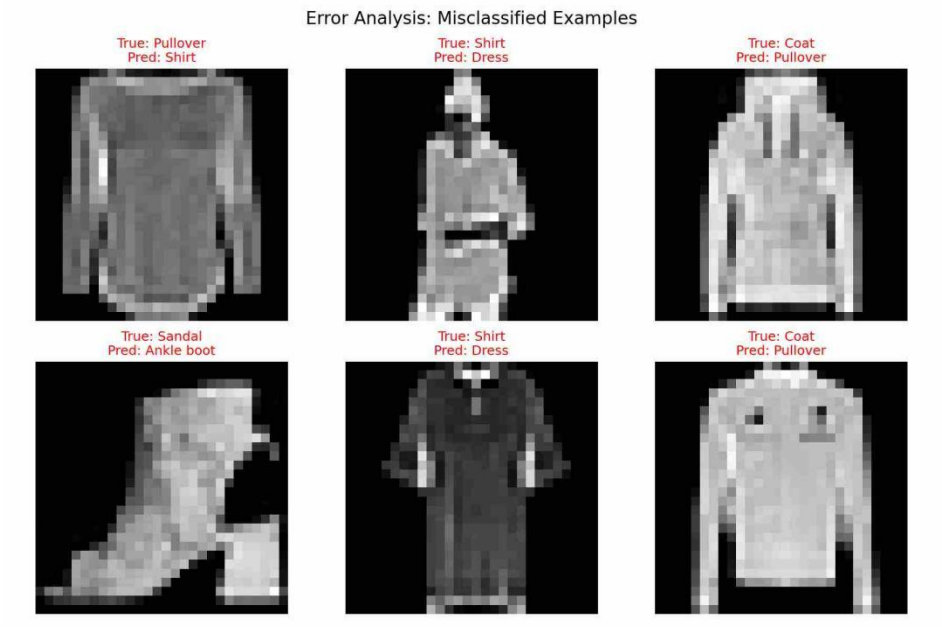

通过对错例的定性分析，判断错误可能是由于以下的几种原因：（1）非局部细节的缺失。在灰度图像中，颜色对比度低，使得衬衫的领口、外套的拉链等关键区分特征丢失。（2）分辨率过低导致的特征模糊。如第四张中由于像素点过于稀疏，凉鞋的镂空部分在降采样过程中可能变得不明显，导致模型误将其识别为实心的靴子。（3）数据集标记的歧义性。如第二张图片中衬衫的设计与裙子高度相似。这说明模型在处理非典型样本时，鲁棒性仍有待提高。为此，在后续的训练过程中，可以采用卷积层进一步提高其细节识别能力。

五.总结与展望

5.1 实验总结

本次实验成功从零实现神经网络全流程，不依赖 pytorch 等深度学习框架，验证集准确率达到 87.8%。在激活函数层面，ReLU/Leaky_ReLU 在收敛上限与初期特征捕捉上表现最佳。在结构方面，128 维隐藏层在收敛速度与稳定性间达到最佳平衡。在正则化层面，本实验对正则化较为敏感，高强度 L2 正则（0.1）会造成模型在损失优化与权重压缩间剧烈震荡。在特征方面，可视化证实神经元已具备提取领口、轮廓等语义特征的能力 ，但仍有部分神经元呈现随机噪声状。

5.2 未来展望

在架构层面，MLP 在前向传播时，必须先将 28×28 的二维图像展平（Flatten）为 784 维的一维向量。这一操作直接破坏了图像原有的空间相邻关系，导致模型只能依靠“全局模板”进行死板匹配，无法有效捕捉诸如“纽扣”、“领口纹理”等局部细粒度特征。这也解释了为何模型经常将轮廓相似的 Shirt（衬衫）和 T-shirt（T 恤）混淆。为此未来可尝试引入卷积神经网络（CNN）以增强局部纹理提取能力。

在算法层面，同时目前采用的基础 SGD 容易在局部极小值附近震荡（如 Epoch 10~15 处），在训练的中后期，Loss 和 Accuracy 曲线仍伴随一定的微小震荡，难以迅速收敛至全局最优点。为此，后续可引入 Momentum 机制或 Adam 优化器，利用梯度的自适应动量来

平滑更新路径，从而加速收敛过程并提升最终性能。

在数据层面，在数据量有限的情况下单纯依赖 L2 正则化防止过拟合手段过于单一。为此，在未来针对 Shirt、Coat 等相似类别的误判，可引入随机翻转、旋转等数据增强手段，提升模型鲁棒性。